

Universidade Federal do Rio Grande do Sul
 Instituto de Informática — INF01017 Aprendizado de Máquina
 Prof^a. Mariana Recamonde Mendoza

Trabalho Prático Final — Parte 1 (T1)

Coleta de dados, Análise Exploratória, Pré-processamento e Spot-checking do conjunto *Car Evaluation*

1 Coleta de dados e identificação do problema

1.1 Origem e contexto do conjunto

O conjunto *Car Evaluation Database*, criado por Bohanec e Rajkovič em 1988, foi derivado de um modelo hierárquico de decisão (DEX) construído originalmente para demonstrar sistemas especialistas multicritério. O conjunto está disponível publicamente no UCI Machine Learning Repository sob o identificador **19** e pode ser acessado em <https://archive.ics.uci.edu/dataset/19/car+evaluation>.

Por construção, o conjunto enumera *todas* as combinações possíveis dos seis atributos preditores ($4 \cdot 4 \cdot 4 \cdot 3 \cdot 3 \cdot 3 = 1728$); a base não foi obtida por amostragem, mas sim pela aplicação determinística do modelo DEX a cada uma das 1.728 instâncias do espaço cartesiano de atributos.

1.2 Pergunta de pesquisa e tarefa preditiva

Pretende-se construir um modelo capaz de **prever a aceitabilidade global de um automóvel** a partir de seis características descritivas. Trata-se, portanto, de um problema de **classificação multiclasse** com quatro rótulos ordenados:

$\text{unacc (inaceitável)} \prec \text{acc (aceitável)} \prec \text{good (bom)} \prec \text{vgood (muito bom)}.$

1.3 Atributos do conjunto

Os seis atributos preditores são todos categóricos, possuem ordem natural e baixa cardinalidade (Tabela 1). A classe possui também ordem natural, o que abre espaço para abordagens *ordinais* de modelagem (avaliadas mais adiante).

Tabela 1: Atributos preditores e respectivos domínios (ordem natural crescente).

Atributo	Significado	Domínio (ordem natural $\rightarrow$)	Cardinalidade
buying	preço de compra	low, med, high, vhigh	4
maint	custo de manutenção	low, med, high, vhigh	4
doors	número de portas	2, 3, 4, 5more	4
persons	capacidade	2, 4, more	3
lug_boot	porta-malas	small, med, big	3
safety	segurança estimada	low, med, high	3

1.4 Justificativa da escolha do conjunto

Foram consideradas as seguintes vantagens para a seleção:

- domínio de fácil interpretação, com atributos auto-explicativos;
- tamanho moderado ($\approx 1,7k$ instâncias), compatível com a abordagem de *spot-checking* prevista no T1;
- ausência de valores faltantes e necessidade mínima de limpeza;
- presença simultânea de classes desbalanceadas e atributos ordinais, o que permitirá discutir vieses indutivos diversos na fase posterior;
- por ter sido gerado a partir de um modelo de regras hierárquicas conhecido, há expectativa de que algoritmos baseados em árvores recuperem boa parte da estrutura — referência útil para comparar diferentes vieses indutivos.

2 Análise exploratória dos dados

2.1 Inspeção inicial e qualidade dos dados

A carga foi feita diretamente do arquivo `car.data`, atribuindo nomes às colunas conforme `car.names` e tipando cada atributo como *categórico ordenado* respeitando sua ordem natural. A inspeção inicial revelou:

- **Dimensões:** 1.728 linhas $\times$ 7 colunas (6 atributos preditores + classe);
- **Valores faltantes:** nenhum (0/1728 em todas as colunas);
- **Linhas duplicadas:** nenhuma — coerente com o fato de o conjunto ser o produto cartesiano completo;
- **Tipos:** todas as variáveis são categóricas; nenhum atributo numérico.

A combinação de dados sem ruído, completos e sem duplicatas indica que **não há demandas de imputação ou remoção** de instâncias.

2.2 Distribuição do atributo alvo

A Figura 1 apresenta a distribuição da variável `class`. A base é **fortemente desbalanceada**: aproximadamente 70 % das instâncias correspondem à classe `unacc`, enquanto as classes `good` e `vgood` somam menos de 8 %. A razão entre a classe majoritária e a minoritária é de aproximadamente $1210/65 \approx 18,6\times$.




Figura 1: Distribuição do atributo alvo `class`. À esquerda, contagens absolutas; à direita, proporções relativas.

Implicações. O desbalanceamento severo torna a acurácia simples uma métrica enganosa: um classificador trivial que sempre prediga `unacc` já alcançaria $\approx 70\%$ de acerto. Em consequência, recomenda-se na fase de *spot-checking*:

- **métrica principal:** F1 macro ou *balanced accuracy*;
- **métricas secundárias:** F1 por classe, matriz de confusão, acurácia;
- **validação cruzada estratificada**, para preservar as proporções (especialmente das classes minoritárias `good` e `vgood`).

2.3 Distribuição dos atributos preditores

A Figura 2 mostra que **todos os atributos têm distribuição marginal exatamente uniforme**: 432 instâncias por valor para os atributos com cardinalidade 4 e 576 instâncias por valor para os atributos com cardinalidade 3.




Figura 2: Distribuição marginal de cada atributo preditor. A uniformidade perfeita decorre da construção do conjunto como produto cartesiano dos domínios.

2.4 Análise bivariada: classe condicionada ao atributo

A Figura 3 apresenta, para cada atributo, a distribuição da classe entre os valores do atributo (proporções normalizadas por linha).




Figura 3: Distribuição condicional $P(\text{classe} \mid \text{atributo})$ para cada um dos seis atributos preditores.

Vários padrões saltam aos olhos:

- **Regras determinísticas:** $\text{safety} = \text{low} \Rightarrow 100\% \text{ unacc}$ ($576/576$) e $\text{persons} = 2 \Rightarrow 100\% \text{ unacc}$ ($576/576$). Estas duas regras isoladas já explicam $960/1210 \approx 79\%$ das instâncias

inaceitáveis, e correspondem a restrições de bom senso (carro sem segurança ou apenas dois lugares dificilmente atende a uma família).

- **Restrição em `lug_boot`:** a classe `vgood` *nunca* ocorre quando `lug_boot` = `small` ($P = 0$).
- **Tendências monotônicas:** `buying` e `maint` apresentam aumento monotônico em $P(\text{unacc})$ à medida que o preço/manutenção sobem; `persons`, `lug_boot` e `safety` mostram comportamento contrário (aumentar o atributo melhora a avaliação).
- **Atributo aparentemente irrelevante:** `doors` produz distribuições praticamente idênticas em todos os seus quatro níveis.

2.5 Heatmap de probabilidades condicionais

Para reforçar visualmente os padrões discutidos, a Figura 4 apresenta as matrizes $P(\text{class} \mid \text{atributo})$ na forma de *heatmap*, com os atributos em ordem natural crescente.




Figura 4: Probabilidade da classe condicionada ao valor de cada atributo. Tons mais escuros indicam maior concentração; as linhas dos atributos estão ordenadas em ordem natural crescente, evidenciando os gradientes de monotonicidade discutidos.

3 Conclusões da análise exploratória

A análise permitiu uma caracterização completa do conjunto e fornece direcionamento concreto para a próxima etapa do trabalho.

Características do conjunto.

1. Tamanho de 1.728 instâncias e seis atributos preditores categóricos ordinais, gerados como produto cartesiano completo — portanto sem aleatoriedade na construção;
2. qualidade dos dados é excelente: nenhum valor faltante, nenhuma duplicata, nenhum *outlier* categórico — todos os atributos têm distribuição marginal exatamente uniforme;

3. o problema é de **classificação multiclasse com classes ordenadas** e fortemente desbalanceadas (razão majoritária/minoritária de $\approx 18,6\times$).

Regras determinísticas observadas.

4. `safety = low` $\Rightarrow$ 100 % unacc (576/576);
5. `persons = 2` $\Rightarrow$ 100 % unacc (576/576);
6. `lug_boot = small` $\Rightarrow$ nunca classifica como vgood.

Implicações para o *spot-checking*.

- **Métrica principal:** F1 macro (ou *balanced accuracy*), em razão do desbalanceamento severo;
- **Métricas secundárias:** acurácia, F1 por classe e matriz de confusão;
- **Validação:** *stratified k-fold* para preservar proporções;

Necessidades de pré-processamento. A EDA aponta as seguintes ações como pertinentes para a fase posterior do trabalho:

- codificação dos atributos categóricos — duas alternativas a se considerar: *ordinal* (preserva a ordem natural identificada) e *one-hot* (trata como nominal);
- tratamento do desbalanceamento (no mínimo, estratificação na validação cruzada);
- avaliar manter ou descartar `doors`, dado que as distribuições de classe são praticamente idênticas em todos os seus quatro níveis.

Referências

- [1] Bohanec, M. & Rajkovič, V. (1988). *Knowledge acquisition and explanation for multi-attribute decision making*. 8th Intl. Workshop on Expert Systems and their Applications, Avignon, France, pp. 59–78.
- [2] Dua, D. & Graff, C. (2019). *UCI Machine Learning Repository*. University of California, Irvine. <https://archive.ics.uci.edu/dataset/19/car+evaluation>
- [3] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- [4] Faceli, K., Lorena, A. C., Gama, J. & Carvalho, A. C. P. L. F. (2021). *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina* (2ª ed.). LTC.