

Universidade Federal do Rio Grande do Sul
Instituto de Informática — INF01017 Aprendizado de Máquina
Prof^ª. Mariana Recamonde Mendoza

Trabalho Prático Final — Parte 1 (T1)

Coleta de dados, Análise Exploratória, Pré-processamento e Spot-checking do conjunto *Car Evaluation*

1 Coleta de dados e identificação do problema

1.1 Origem e contexto do conjunto

O conjunto *Car Evaluation Database*, criado por Bohanec e Rajkovič em 1988, foi derivado de um modelo hierárquico de decisão (DEX) construído originalmente para demonstrar sistemas especialistas multicritério. O conjunto está disponível publicamente no UCI Machine Learning Repository sob o identificador **19** e pode ser acessado em <https://archive.ics.uci.edu/dataset/19/car+evaluation>.

Por construção, o conjunto enumera *todas* as combinações possíveis dos seis atributos preditores ($4 \cdot 4 \cdot 4 \cdot 3 \cdot 3 \cdot 3 = 1728$); a base não foi obtida por amostragem, mas sim pela aplicação determinística do modelo DEX a cada uma das 1.728 instâncias do espaço cartesiano de atributos.

1.2 Pergunta de pesquisa e tarefa preditiva

Pretende-se construir um modelo capaz de **prever a aceitabilidade global de um automóvel** a partir de seis características descritivas. Trata-se, portanto, de um problema de **classificação multiclasse** com quatro rótulos ordenados:

$\text{unacc (inaceitável)} \prec \text{acc (aceitável)} \prec \text{good (bom)} \prec \text{vgood (muito bom)}.$

1.3 Atributos do conjunto

Os seis atributos preditores são todos categóricos, possuem ordem natural e baixa cardinalidade (Tabela 1). A classe possui também ordem natural, o que abre espaço para abordagens *ordinais* de modelagem (avaliadas mais adiante).

Tabela 1: Atributos preditores e respectivos domínios (ordem natural crescente).

Atributo	Significado	Domínio (ordem natural $\rightarrow$)	Cardinalidade
buying	preço de compra	low, med, high, vhigh	4
maint	custo de manutenção	low, med, high, vhigh	4
doors	de portas	2, 3, 4, 5more	4
persons	capacidade	2, 4, more	3
lug_boot	porta-malas	small, med, big	3
safety	segurança estimada	low, med, high	3

1.4 Justificativa da escolha do conjunto

Foram consideradas as seguintes vantagens para a seleção:

- domínio de fácil interpretação, com atributos auto-explicativos;
- tamanho moderado ($\approx 1,7k$ instâncias), compatível com a abordagem de *spot-checking* prevista no T1;
- ausência de valores faltantes e necessidade mínima de limpeza;
- presença simultânea de classes desbalanceadas e atributos ordinais, o que permitirá discutir vieses indutivos diversos na fase posterior;
- por ter sido gerado a partir de um modelo de regras hierárquicas conhecido, há expectativa de que algoritmos baseados em árvores recuperem boa parte da estrutura — referência útil para comparar diferentes vieses indutivos.

2 Análise exploratória dos dados

2.1 Inspeção inicial e qualidade dos dados

A carga foi feita diretamente do arquivo `car.data`, atribuindo nomes às colunas conforme `car.names` e tipando cada atributo como *categórico ordenado* respeitando sua ordem natural. A inspeção inicial revelou:

- **Dimensões:** 1.728 linhas $\times$ 7 colunas (6 atributos preditores + classe);
- **Valores faltantes:** nenhum (0/1728 em todas as colunas);
- **Linhas duplicadas:** nenhuma — coerente com o fato de o conjunto ser o produto cartesiano completo;
- **Tipos:** todas as variáveis são categóricas; nenhum atributo numérico.

A combinação de dados sem ruído, completos e sem duplicatas indica que **não há demandas de imputação ou remoção** de instâncias.

2.2 Distribuição do atributo alvo

A Figura 1 apresenta a distribuição da variável `class`. A base é **fortemente desbalanceada**: aproximadamente 70 % das instâncias correspondem à classe `unacc`, enquanto as classes `good` e `vgood` somam menos de 8 %. A razão entre a classe majoritária e a minoritária é de aproximadamente $1210/65 \approx 18,6\times$.




Figura 1: Distribuição do atributo alvo *class*. À esquerda, contagens absolutas; à direita, proporções relativas.

Implicações. O desbalanceamento severo torna a acurácia simples uma métrica enganosa: um classificador trivial que sempre prediga *unacc* já alcançaria $\approx 70\%$ de acerto. Em consequência, recomenda-se na fase de *spot-checking*:

- **métrica principal:** F1 macro ou *balanced accuracy*;
- **métricas secundárias:** F1 por classe, matriz de confusão, acurácia;
- **validação cruzada estratificada**, para preservar as proporções (especialmente das classes minoritárias *good* e *vgood*).

2.3 Distribuição dos atributos preditores

A Figura 2 mostra que **todos os atributos têm distribuição marginal exatamente uniforme**: 432 instâncias por valor para os atributos com cardinalidade 4 e 576 instâncias por valor para os atributos com cardinalidade 3.




Figura 2: Distribuição marginal de cada atributo preditor. A uniformidade perfeita decorre da construção do conjunto como produto cartesiano dos domínios.

2.4 Análise bivariada: classe condicionada ao atributo

A Figura 3 apresenta, para cada atributo, a distribuição da classe entre os valores do atributo (proporções normalizadas por linha).




Figura 3: Distribuição condicional $P(\text{classe} \mid \text{atributo})$ para cada um dos seis atributos preditores.

Vários padrões saltam aos olhos:

- **Regras determinísticas:** $\text{safety} = \text{low} \Rightarrow 100\% \text{ unacc}$ ($576/576$) e $\text{persons} = 2 \Rightarrow 100\% \text{ unacc}$ ($576/576$). Estas duas regras isoladas já explicam $960/1210 \approx 79\%$ das instâncias

inaceitáveis, e correspondem a restrições de bom senso (carro sem segurança ou apenas dois lugares dificilmente atende a uma família).

- **Restrição em `lug_boot`:** a classe `vgood` *nunca* ocorre quando `lug_boot` = `small` ($P = 0$).
- **Tendências monotônicas:** `buying` e `maint` apresentam aumento monotônico em $P(\text{unacc})$ à medida que o preço/manutenção sobem; `persons`, `lug_boot` e `safety` mostram comportamento contrário (aumentar o atributo melhora a avaliação).
- **Atributo aparentemente irrelevante:** `doors` produz distribuições praticamente idênticas em todos os seus quatro níveis.

2.5 Heatmap de probabilidades condicionais

Para reforçar visualmente os padrões discutidos, a Figura 4 apresenta as matrizes $P(\text{class} \mid \text{atributo})$ na forma de *heatmap*, com os atributos em ordem natural crescente.




Figura 4: Probabilidade da classe condicionada ao valor de cada atributo. Tons mais escuros indicam maior concentração; as linhas dos atributos estão ordenadas em ordem natural crescente, evidenciando os gradientes de monotonicidade discutidos.

3 Conclusões da análise exploratória

A análise permitiu uma caracterização completa do conjunto e fornece direcionamento concreto para a próxima etapa do trabalho.

Características do conjunto.

1. Tamanho de 1.728 instâncias e seis atributos preditores categóricos ordinais, gerados como produto cartesiano completo — portanto sem aleatoriedade na construção;
2. qualidade dos dados é excelente: nenhum valor faltante, nenhuma duplicata, nenhum *outlier* categórico — todos os atributos têm distribuição marginal exatamente uniforme;

- o problema é de **classificação multiclasse com classes ordenadas** e fortemente desbalanceadas (razão majoritária/minoritária de $\approx 18,6\times$).

Regras determinísticas observadas.

- `safety = low` $\Rightarrow$ 100 % unacc (576/576);
- `persons = 2` $\Rightarrow$ 100 % unacc (576/576);
- `lug_boot = small` $\Rightarrow$ nunca classifica como vgood.

Implicações para o *spot-checking*.

- Métrica principal:** F1 macro (ou *balanced accuracy*), em razão do desbalanceamento severo;
- Métricas secundárias:** acurácia, F1 por classe e matriz de confusão;
- Validação:** *stratified k-fold* para preservar proporções;

Necessidades de pré-processamento. A EDA aponta as seguintes ações como pertinentes para a fase posterior do trabalho:

- codificação dos atributos categóricos — duas alternativas a se considerar: *ordinal* (preserva a ordem natural identificada) e *one-hot* (trata como nominal);
- tratamento do desbalanceamento (no mínimo, estratificação na validação cruzada);
- avaliar manter ou descartar `doors`, dado que as distribuições de classe são praticamente idênticas em todos os seus quatro níveis.

4 Treinamento do modelo

4.1 Algoritmos e Métricas de desempenho

Para o treinamento, a técnica utilizada foi a Validação Cruzada com 5 folds, utilizando duas seeds, 94 e 42. **Algoritmos utilizados:**

- K-nearest neighbors
- Regressão Logística
- Árvore de decisão
- Rede Neural
- Naive Bayes
- SVM
- Florestas Aleatórias
- AdaBoost

Métricas utilizadas

- Acurácia
- Acurácia balanceada
- Recall
- Precisão
- F1-Micro
- F1-Macro
- ROC-AUC

4.2 Scores obtidos para cada algoritmo de acordo com sua seed

Exibindo resultados da seed 16					
Reg. Log			KNN		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.8256	0.0214	acurácia	0.9443	0.0196
acurácia_balanceada	0.657	0.0695	acurácia_balanceada	0.8315	0.0567
recall	0.657	0.0695	recall	0.8315	0.0567
precisão	0.7409	0.046	precisão	0.903	0.0504
f1_micro	0.8256	0.0214	f1_micro	0.9443	0.0196
f1_macro:	0.6834	0.0547	f1_macro:	0.859	0.0569
roc_auc	0.9487	0.0079	roc_auc	0.9866	0.0058

Árvore de Decisão			Rede Neural		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.9103	0.016	acurácia	0.9385	0.0214
acurácia_balanceada	0.7844	0.0581	acurácia_balanceada	0.8766	0.0593
recall	0.7844	0.0581	recall	0.8766	0.0593
precisão	0.8127	0.0589	precisão	0.8925	0.0371
f1_micro	0.9103	0.016	f1_micro	0.9385	0.0214
f1_macro:	0.7806	0.054	f1_macro:	0.8782	0.0468
roc_auc	0.9779	0.0052	roc_auc	0.9923	0.0032

Naive Bayes			SVM		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.6968	0.0149	acurácia	0.9537	0.0177
acurácia_balanceada	0.5787	0.0262	acurácia_balanceada	0.883	0.0457
recall	0.5787	0.0262	recall	0.883	0.0457
precisão	0.5601	0.0681	precisão	0.9369	0.0322
f1_micro	0.6968	0.0149	f1_micro	0.9537	0.0177
f1_macro:	0.4516	0.0327	f1_macro:	0.9016	0.0418
roc_auc	0.897	0.0101	roc_auc	0.9967	0.0019

Random Forest			AdaBoost		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.9703	0.009	acurácia	0.8669	0.021
acurácia_balanceada	0.927	0.0398	acurácia_balanceada	0.6324	0.0701
recall	0.927	0.0398	recall	0.6324	0.0701
precisão	0.938	0.0269	precisão	0.6987	0.1231
f1_micro	0.9703	0.009	f1_micro	0.8669	0.021
f1_macro:	0.9281	0.0301	f1_macro:	0.6285	0.0762
roc_auc	0.9982	0.0009	roc_auc	0.9339	0.0032

Figura 5: Scores obtidos com a seed 16

Exibindo resultados da seed 67					
Reg. Log			KNN		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.8336	0.0293	acurácia	0.9385	0.0114
acurácia_balanceada	0.6789	0.0529	acurácia_balanceada	0.8214	0.03
recall	0.6789	0.0529	recall	0.8214	0.03
precisão	0.7447	0.0619	precisão	0.8922	0.0402
f1_micro	0.8336	0.0293	f1_micro	0.9385	0.0114
f1_macro	0.7009	0.0547	f1_macro	0.8495	0.03
roc_auc	0.9488	0.0143	roc_auc	0.9874	0.0024

Árvore de Decisão			Rede Neural		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.8987	0.0109	acurácia	0.9428	0.0189
acurácia_balanceada	0.6533	0.0442	acurácia_balanceada	0.8862	0.0298
recall	0.6533	0.0442	recall	0.8862	0.0298
precisão	0.6574	0.1358	precisão	0.8954	0.0414
f1_micro	0.8987	0.0109	f1_micro	0.9428	0.0189
f1_macro	0.6282	0.0601	f1_macro	0.8843	0.0319
roc_auc	0.9647	0.0051	roc_auc	0.9921	0.0032

Naive Bayes			SVM		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.6997	0.025	acurácia	0.9508	0.0111
acurácia_balanceada	0.5712	0.0326	acurácia_balanceada	0.8714	0.03
recall	0.5712	0.0326	recall	0.8714	0.03
precisão	0.5651	0.0988	precisão	0.919	0.0293
f1_micro	0.6997	0.025	f1_micro	0.9508	0.0111
f1_macro	0.4447	0.0464	f1_macro	0.886	0.0169
roc_auc	0.8957	0.0112	roc_auc	0.9961	0.002

Random Forest			AdaBoost		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.9703	0.0138	acurácia	0.8466	0.0168
acurácia_balanceada	0.9326	0.0159	acurácia_balanceada	0.5745	0.0649
recall	0.9326	0.0159	recall	0.5745	0.0649
precisão	0.9486	0.0314	precisão	0.6072	0.0888
f1_micro	0.9703	0.0138	f1_micro	0.8466	0.0168
f1_macro	0.9368	0.0247	f1_macro	0.5619	0.0687
roc_auc	0.998	0.0011	roc_auc	0.9356	0.009

Figura 6: Scores obtidos com a seed 67

Exibindo resultados da seed 94					
Reg. Log			KNN		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.8278	0.0122	acurácia	0.9255	0.0067
acurácia_balanceada	0.6526	0.042	acurácia_balanceada	0.7605	0.035
recall	0.6526	0.042	recall	0.7605	0.035
precisão	0.6953	0.0329	precisão	0.8478	0.0341
f1_micro	0.8278	0.0122	f1_micro	0.9255	0.0067
f1_macro	0.6655	0.037	f1_macro	0.7912	0.0269
roc_auc	0.952	0.0067	roc_auc	0.9817	0.0061

Árvore de Decisão			Rede Neural		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.9096	0.0182	acurácia	0.9356	0.014
acurácia_balanceada	0.737	0.0346	acurácia_balanceada	0.8675	0.0495
recall	0.737	0.0346	recall	0.8675	0.0495
precisão	0.8234	0.0479	precisão	0.8863	0.0319
f1_micro	0.9096	0.0182	f1_micro	0.9356	0.014
f1_macro	0.7469	0.0291	f1_macro	0.8737	0.0385
roc_auc	0.9765	0.0034	roc_auc	0.9917	0.0027

Naive Bayes			SVM		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.7142	0.0187	acurácia	0.9544	0.0084
acurácia_balanceada	0.5817	0.024	acurácia_balanceada	0.8687	0.0236
recall	0.5817	0.024	recall	0.8687	0.0236
precisão	0.5736	0.052	precisão	0.9275	0.0334
f1_micro	0.7142	0.0187	f1_micro	0.9544	0.0084
f1_macro	0.4612	0.034	f1_macro	0.8934	0.022
roc_auc	0.9011	0.0059	roc_auc	0.9962	0.0023

Random Forest			AdaBoost		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.9682	0.007	acurácia	0.8408	0.0109
acurácia_balanceada	0.9173	0.0477	acurácia_balanceada	0.6151	0.079
recall	0.9173	0.0477	recall	0.6151	0.079
precisão	0.9353	0.0118	precisão	0.6913	0.0918
f1_micro	0.9682	0.007	f1_micro	0.8408	0.0109
f1_macro	0.9232	0.0324	f1_macro	0.6225	0.0823
roc_auc	0.9981	0.0007	roc_auc	0.9348	0.0072

Figura 7: Scores obtidos com a seed 94

Exibindo resultados da seed 42					
Reg. Log			KNN		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.8234	0.0209	acurácia	0.9421	0.01
acurácia_balanceada	0.658	0.0634	acurácia_balanceada	0.8505	0.0426
recall	0.658	0.0634	recall	0.8505	0.0426
precisão	0.7372	0.0747	precisão	0.9179	0.0272
f1_micro	0.8234	0.0209	f1_micro	0.9421	0.01
f1_macro	0.676	0.0623	f1_macro	0.8759	0.0252
roc_auc	0.9468	0.0057	roc_auc	0.9865	0.0038

Árvore de Decisão			Rede Neural		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.8987	0.0312	acurácia	0.9255	0.0197
acurácia_balanceada	0.7394	0.0527	acurácia_balanceada	0.8367	0.0442
recall	0.7394	0.0527	recall	0.8367	0.0442
precisão	0.7863	0.0574	precisão	0.868	0.0377
f1_micro	0.8987	0.0312	f1_micro	0.9255	0.0197
f1_macro	0.7422	0.0484	f1_macro	0.8436	0.0374
roc_auc	0.9751	0.006	roc_auc	0.9902	0.0041

Naive Bayes			SVM		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.7004	0.0172	acurácia	0.9522	0.0126
acurácia_balanceada	0.572	0.0255	acurácia_balanceada	0.8804	0.0389
recall	0.572	0.0255	recall	0.8804	0.0389
precisão	0.5462	0.0473	precisão	0.9263	0.0233
f1_micro	0.7004	0.0172	f1_micro	0.9522	0.0126
f1_macro	0.4438	0.0272	f1_macro	0.8947	0.0189
roc_auc	0.8991	0.007	roc_auc	0.9964	0.0022

Random Forest			AdaBoost		
	media	desvio_padrao		media	desvio_padrao
acurácia	0.9725	0.0029	acurácia	0.8539	0.028
acurácia_balanceada	0.9109	0.0411	acurácia_balanceada	0.6204	0.0857
recall	0.9109	0.0411	recall	0.6204	0.0857
precisão	0.9416	0.0312	precisão	0.6372	0.0779
f1_micro	0.9725	0.0029	f1_micro	0.8539	0.028
f1_macro	0.9236	0.0326	f1_macro	0.6119	0.0883
roc_auc	0.9985	0.0005	roc_auc	0.9357	0.0015

Figura 8: Scores obtidos com a seed 42

4.3 Boxplots de cada métrica organizados por seeds




Figura 9: Boxplot da acurácia balanceada




Figura 10: Boxplot da acurácia




Figura 11: Boxplot do F1-Macro




Figura 12: Boxplot do F1-Micro




Figura 13: Boxplot da precisão




Figura 14: Boxplot do recall




Figura 15: Boxplot do ROC-AUC

4.4 Matriz de confusão dos algoritmos analisados

4.5 Matriz de confusão dos algoritmos analisados




Figura 16: Matriz de confusão do algoritmo Árvore de decisão




Figura 17: Matriz de confusão do algoritmo de Florestas Aleatórias

Lorem ipsum




Figura 18: Matriz de confusão do algoritmo Naive Bayes




Figura 19: Matriz de confusão do algoritmo de Regressão Logística

aaaa




Figura 20: Matriz de confusão do algoritmo K-nearest neighbors com $K = 5$




Figura 21: Matriz de confusão utilizando Redes Neurais

aaaa




Figura 22: Matriz de confusão do algoritmo AdaBoost




Figura 23: Matriz de confusão do algoritmo SVM

Texto abaixo das últimas figuras.

4.6 Conclusões sobre os algoritmos avaliados

Considerando as métricas analisadas, o algoritmo que apresentou melhor desempenho foi o algoritmo de Florestas Aleatórias, com o F1-macro tendo um score de 0.9232 e uma acurácia balanceada de 0.9173. Devemos considerar essas duas métricas com mais rigor devido à natureza dos dados serem desbalanceadas, como visto na seção 3. Entretanto, é interessante observar o comportamento coerente entre as métricas utilizadas e a natureza dos dados, onde todas as métricas utilizadas para dados balanceados se mostram elevadas de forma otimista. Também podemos observar através da matriz de confusão que o modelo se adaptou muito bem para a predição de classes positivas, tendo apenas um desempenho inferior para classificar carros como acc (acceptable).

Referências

- [1] Bohanec, M. & Rajkovič, V. (1988). *Knowledge acquisition and explanation for multi-attribute decision making*. 8th Intl. Workshop on Expert Systems and their Applications, Avignon, France, pp. 59–78.
- [2] Dua, D. & Graff, C. (2019). *UCI Machine Learning Repository*. University of California, Irvine. <https://archive.ics.uci.edu/dataset/19/car+evaluation>
- [3] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825–2830.
- [4] Faceli, K., Lorena, A. C., Gama, J. & Carvalho, A. C. P. L. F. (2021). *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina* (2ª ed.). LTC.